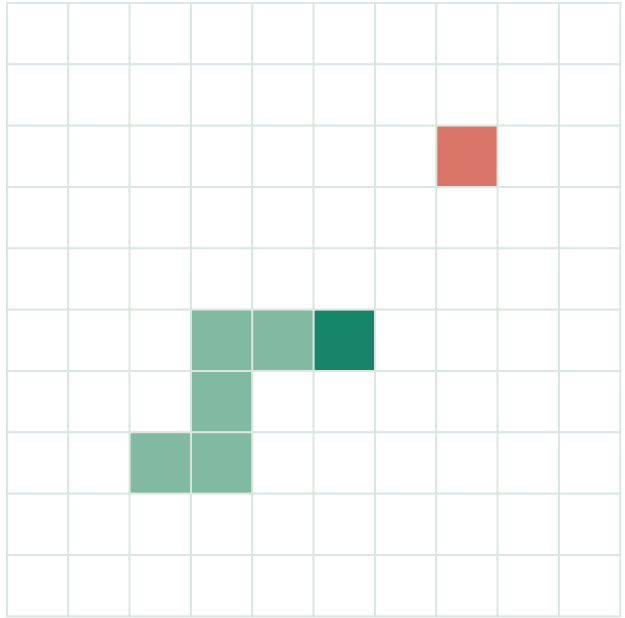
基于深度强化学习的贪吃蛇智能体

设计与实验研究

DQN / Double DQN / Dueling DQN



环境示意

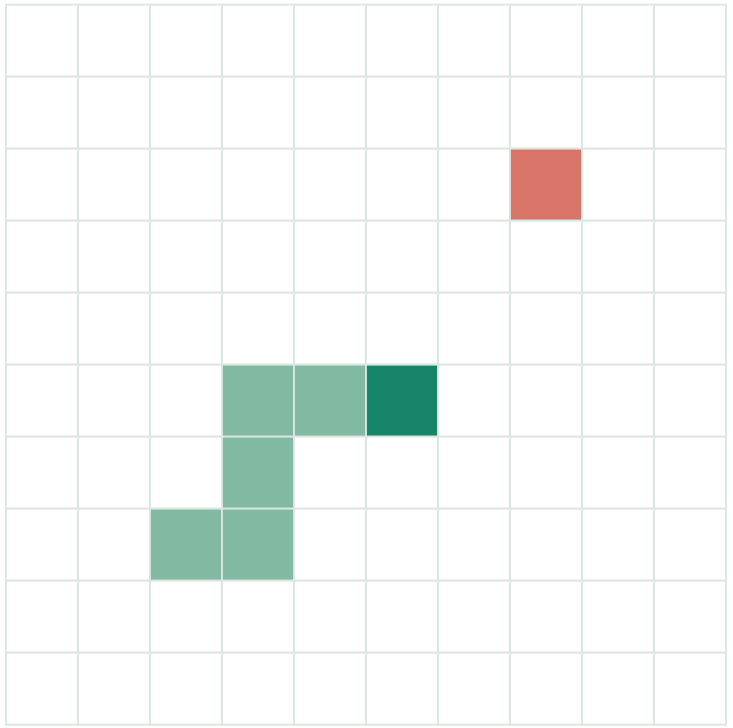
强化学习课程小组汇报

潘明东、张欣怡、张娄瑞、周欣语

2026 年 10 月

环境与强化学习建模

稀疏反馈与动态蛇身，使简单规则形成长期决策问题



环境示意

10×10 棋盘，初始蛇长 3
动作：直行、左转、右转
奖励：食物 +10，死亡 −10，移动 0

观测 → **动作** → **奖励 / 新观测**

碰撞或满盘：终止
达到 500 步：截断

状态表示：11 维与 20 维

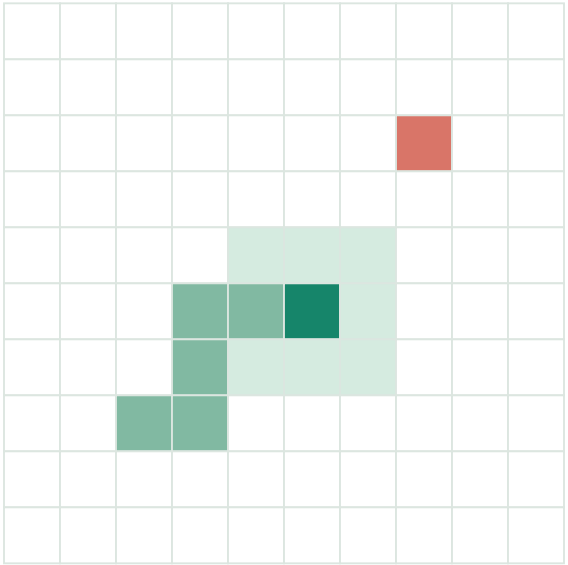
V1 提供紧凑基线，V2 增加距离与相对局部障碍

V1　11 维

危险 3 + 朝向 4 + 食物方位 4

V2　11 + 1 + 8 = 20 维

增加归一化食物距离与相对八邻域障碍



环境示意

规则一致：允许进入当步腾出的旧尾格

DQN 与统一训练框架

经验回放与目标网络支持价值学习，三种算法共用运行流程

环境交互 → **经验回放** → **采样批次** → **Online 更新**

Target 网络提供下一状态价值

$$y = r + \gamma(1 - \text{terminated}) \max Q_target(s', a')$$

epsilon-greedy 探索；截断仍 bootstrap
统一训练、评估与模型加载，自动保存配置和日志

统一实验协议

同组只改变研究变量，所有训练种子完整报告

项目	设置
对照训练	每条件 3 个训练种子：42、43、44
预算	每模型 100,000 环境步
网络与参数	两层各 128；γ=0.99，学习率 0.001
独立评估	每模型 50 局，纯贪心、不更新网络
核心指标	食物数 Score；跨模型均值与总体 SD

开发、复核、最终测试使用不同环境种子集

Double DQN：选择与评价分离

Online 选择动作，Target 评价该动作

DQN Target 选最大 → Target 评价

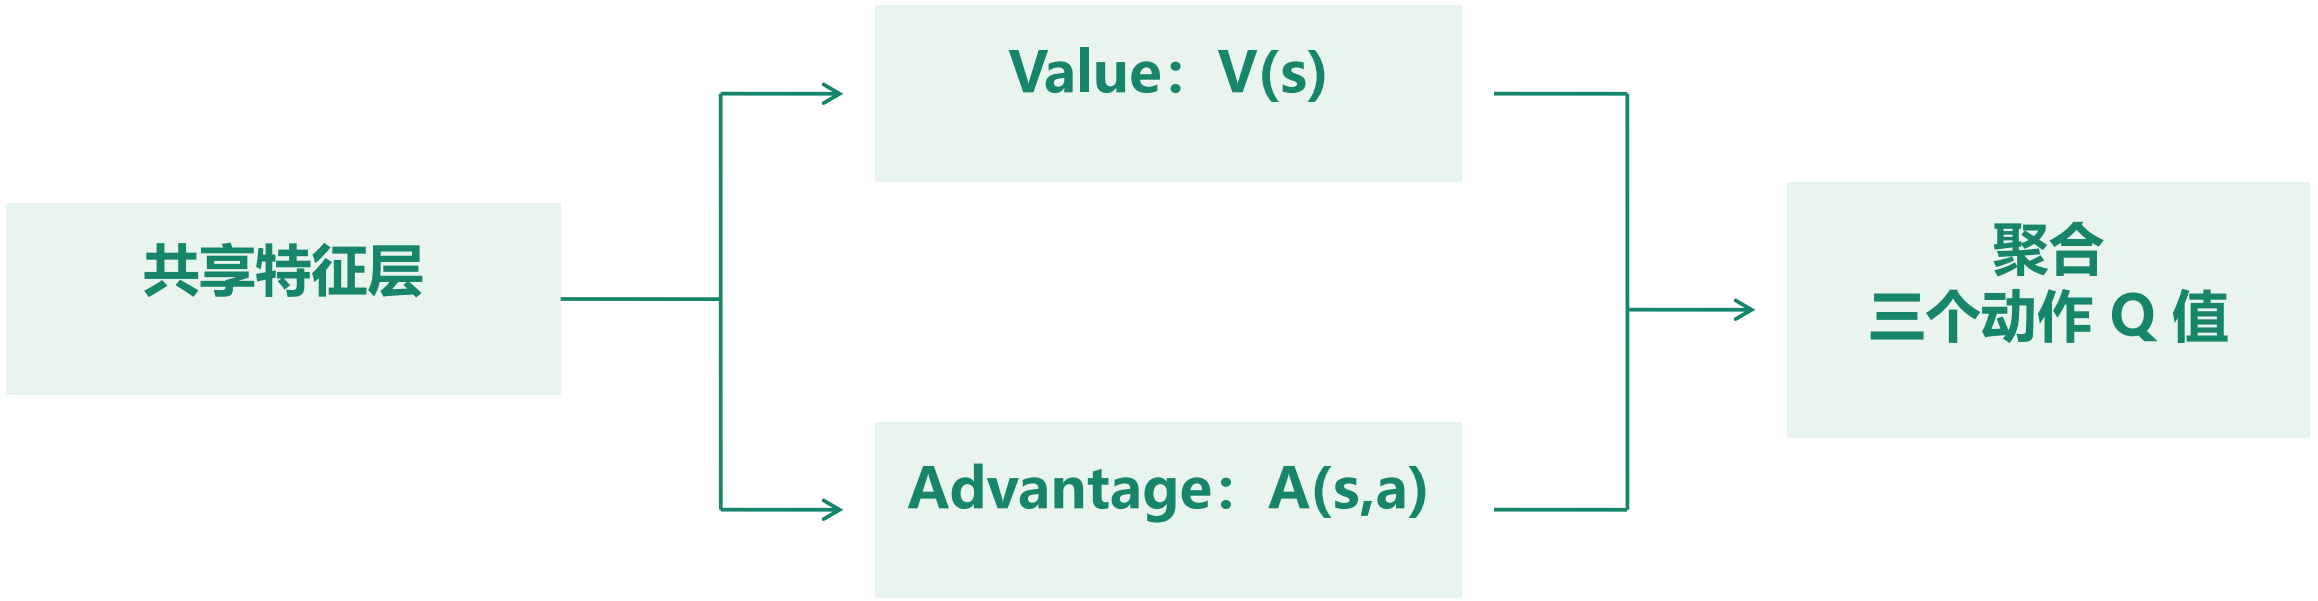
Double Online 选动作 → Target 评价

$$Q_{target}(s', \text{argmax } Q_{online}(s', a'))$$

只改变目标计算，不增加网络参数

Dueling DQN：状态价值与动作优势

共享特征后分别估计 V 与 A，再聚合为三个动作的 Q 值

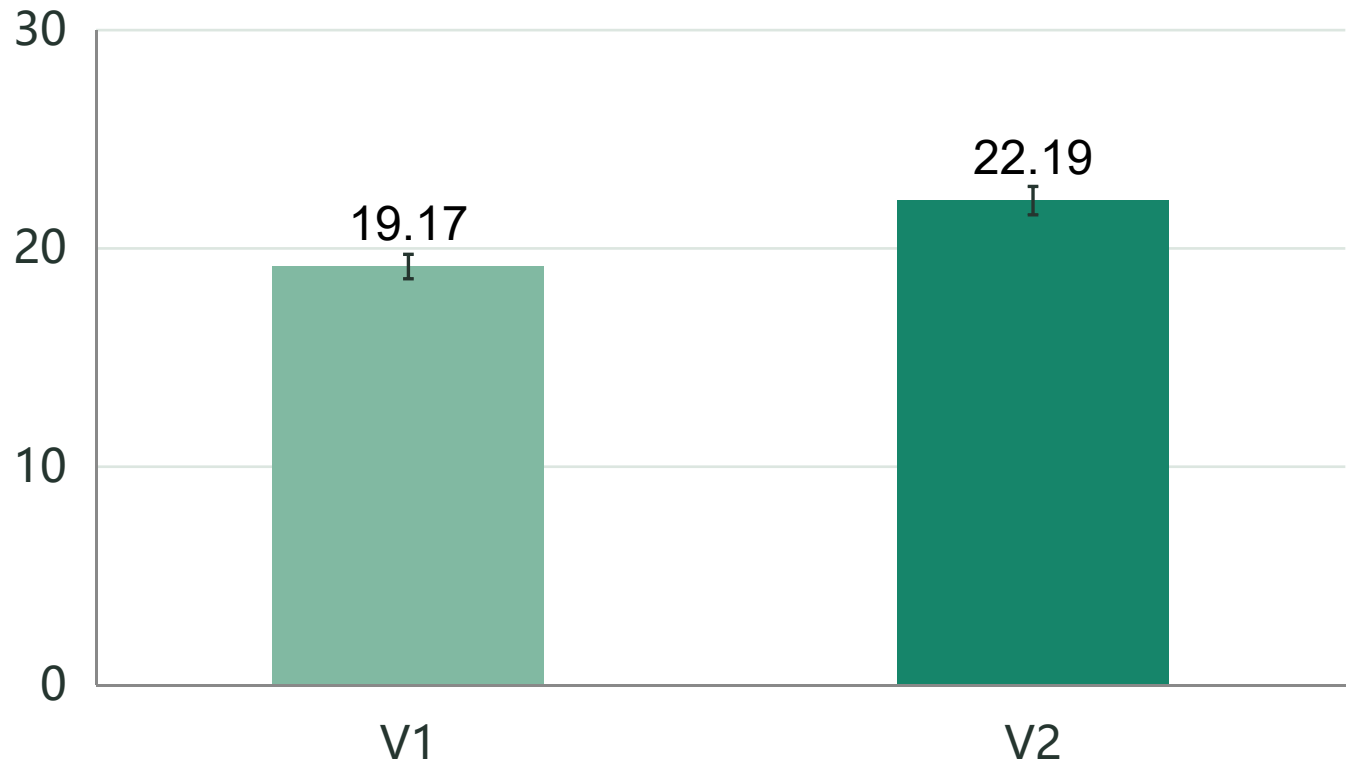


$$Q(s,a) = V(s) + A(s,a) - \text{mean } A(s,a')$$

沿用标准 DQN target，共享公共训练流程

V2 每局均分提高约 15.72%

固定 DQN + sparse，仅改变状态表示



+15.72%

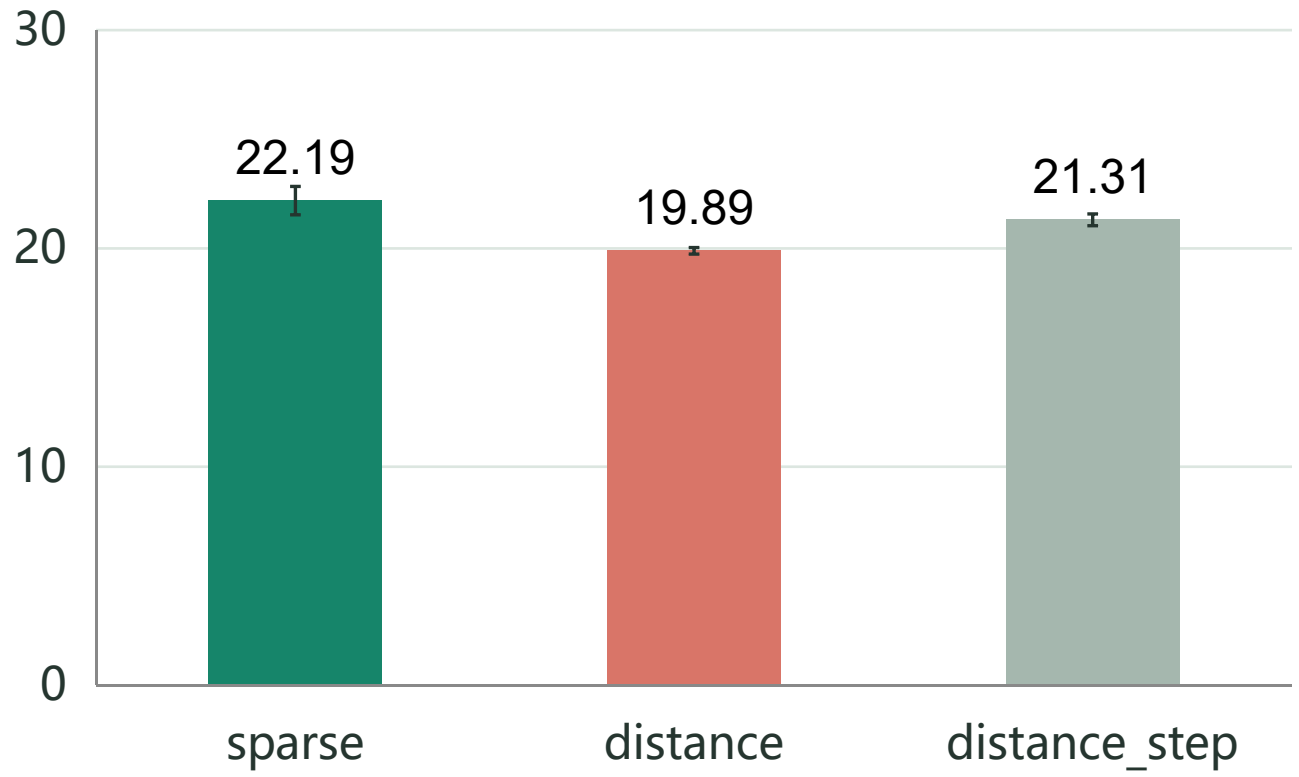
V1 19.17 ± 0.56
V2 22.19 ± 0.65

每局得分改善
未证明更稳定或寻食更高效

误差棒：模型评估均分的跨训练种子总体 SD（3 seeds，ddof=0）

奖励塑形：更密集反馈未提高均分

固定 V2 + DQN，距离系数 0.1，步惩罚 0.01



误差棒：跨训练种子总体 SD（ddof=0）；三组 SD：0.65 / 0.15 / 0.27

Return 216.16 > 211.87，但食物更少；跨奖励按 Score 比较

sparse

食物 +10，死亡 −10

distance

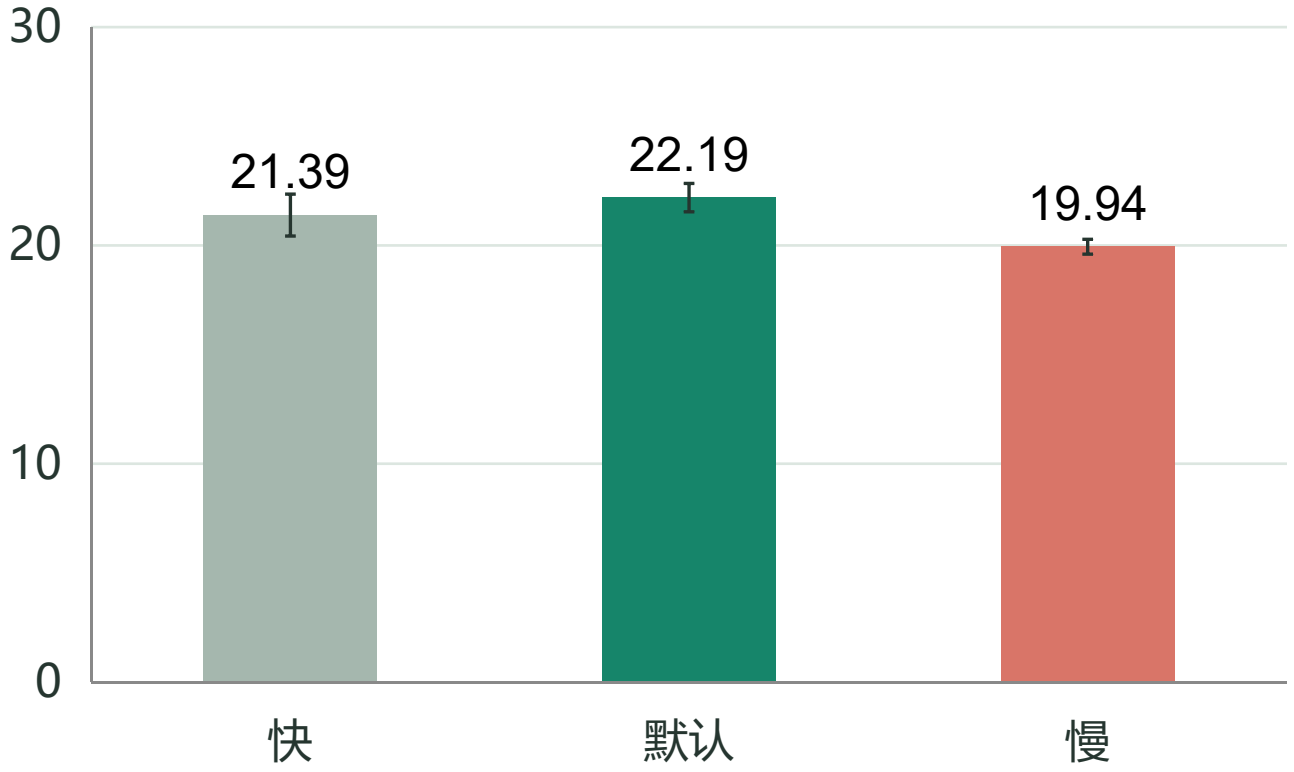
额外奖励 0.1 × 距离减少量

distance_step

distance 每动作再减 0.01

默认探索衰减在本次对照中均分最高

固定 DQN + V2 + sparse，仅改变 epsilon 的衰减速度



快　0.9998
默认　0.9999
慢　0.99995

epsilon：1.0 → 0.05
按训练环境步更新

训练得分早升 ≠ 最终贪心策略更好

Score：21.39 ± 0.96 / 22.19 ± 0.65 / 19.94 ± 0.34；误差为跨 seed 总体 SD

综合比较与五种子最终验证

三算法共同配置：V2 + sparse + 默认探索

算法	开发均分 ± SD	新种子复核均分 ± SD
DQN	22.19 ± 0.65	21.45 ± 1.49
Double DQN	19.77 ± 0.74	19.89 ± 1.01
Dueling DQN	21.01 ± 1.01	20.83 ± 0.86
Random	0.04	0.12

五训练种子最终确认

开发集 **22.60 ± 1.19**　　最终新测试 **20.76 ± 2.64**

冻结 DQN + V2 + sparse + 0.9999；最终 Random = 0.12

上表 3 seeds，下方 5 seeds；± 为跨模型均分总体 SD，两个复核/测试集不同

总结：改进需要实验验证

统一环境与三种算法

状态、奖励、探索对照，交互消融与五种子最终测试

V2 改善每局得分

密集奖励、探索调整与结构改动均需实际检验

局限：种子与预算有限，未证明显著性或普遍最优

A 环境与 V1　B DQN 与框架　C 改进算法　D V2 与实验分析